Введение в искусственные нейронные сети ¶

Урок 3. TensorFlow

Практическое задание

- 1. Постройте нейронную сеть (берём простую линейную сеть, которую разбирали на уроке: меняем число слоёв, число нейронов, типы активации, тип оптимизатора) на датасете from sklern.datasets import load_boston.
- 2. Измените функцию потерь и метрику для этой задачи. Постройте 10-15 вариантов и сведите результаты их работы в таблицу. Опишите, какого результата вы добились от нейросети? Что помогло вам улучшите её точность?
- 3. Поработайте с документацией TensorFlow 2. Найти 2-3 полезные команды TensorFlow, не разобранные на уроке (полезные для Вас).
- 1-2.(*) Попробуйте обучить нейронную сеть на TensorFlow 2 на датасете imb_rewiews. Опишите, какого результата вы добились от нейросети? Что помогло вамулучшить её точность?

Выполнил Соковнин И.Л.

Boston House Prices

The Boston Housing Dataset - https://www.kaggle.com/prasadperera/the-boston-housing-dataset/data (https://www.kaggle.com/prasadperera/the-boston-housing-dataset/dataset/dataset/dataset/dataset/dataset/dataset/dataset/dataset/

https://www.machinelearningmastery.ru/linear-regression-on-boston-housing-dataset-f409b7e4a155/ (https://www.machinelearningmastery.ru/linear-regression-on-boston-housing-dataset-f409b7e4a155/)

Data: housing.csv(49.08 kB) - Boston House Price dataset

0.00632 18.00 2.310 0 0.5380 6.5750 65.20 4.0900 1 296.0 15.30 396.90 4.98 24.00

- CRIM: per capita crime rate by town
- ZN: proportion of residential land zoned for lots over 25,000 sq.ft.
- INDUS: proportion of non-retail business acres per town
- CHAS: Charles River dummy variable (= 1 if tract bounds river; 0 otherwise)
- NOX: nitric oxides concentration (parts per 10 million)
- RM: average number of rooms per dwelling
- AGE: proportion of owner-occupied units built prior to 1940
- DIS: weighted distances to five Boston employment centres
- · RAD: index of accessibility to radial highways
- TAX: full-value property-tax rate per \$10,000
- PTRATIO: pupil-teacher ratio by town
- B: 1000(Bk 0.63)^2 where Bk is the proportion of blacks by town
- LSTAT: % lower status of the population
- MEDV: Median value of owner-occupied homes in \$1000's
- CRIM: уровень преступности на душу населения по городам
- ZN: доля земли под жилую застройку зонирована на участки площадью более 25 000 кв. футов.
- INDUS: доля акров, не относящихся к розничной торговле, на город
- CHAS: фиктивная переменная Charles River (= 1, если участок ограничивает реку; 0 в противном случае)
- NOX: концентрация оксидов азота (частей на 10 миллионов)
- RM: среднее количество комнат в доме в PM
- AGE: доля единиц, занимаемых владельцами, построенных до 1940 г.
- DIS: взвешенные расстояния до пяти бостонских центров занятости
- RAD: индекс доступности радиальных автомобильных дорог
- ТАХ: ставка налога на имущество в размере полной стоимости из расчета 10 000 долларов США.
- PTRATIO: сСоотношение учеников и учителей по городам
- B: 1000 (Bk 0,63) ^ 2, где Bk доля черных по городам
- LSTAT: % более низкий статус населения
- MEDV: средняя стоимость домов, занимаемых владельцами, в 1000 долларов США.
- 1. Как меняется нейронная сеть под действием задачи?
- 2. Выход не м.б. ограниченным => либо 'relu' либо линейная.
- 3. loss должен учитывать характеристики задачи.
- 4. Метрика учитывает вид выхода, тип задачи (при выборе потерь и метрики):
 - квадратичная ошибка, абсолютная ошибка, коэффициент детерминации

```
B [33]: import numpy as np
        import pandas as pd
        import matplotlib.pyplot as plt
        import tensorflow as tf
        from tensorflow import keras
        from tensorflow.keras.models import Sequential
        from tensorflow.keras.layers import Dense
        from tensorflow.keras.utils import to_categorical
        from sklearn.metrics import r2_score
B [34]: from tensorflow.keras.optimizers import Adam, SGD, RMSprop, Adagrad # Оптимизаторы
B [35]: |print(tf.__version__)
        2.9.0-dev20211226
B [36]: # !conda install -c anaconda scikit-learn
       # !pip3 install -U scikit-learn
B [37]:
B [38]: | from sklearn.datasets import load_boston
B [39]: boston_dataset = load_boston()
        C:\ProgramData\Anaconda3\lib\site-packages\sklearn\utils\deprecation.py:87: FutureWarning: Function load_boston is depr
        ecated; `load_boston` is deprecated in 1.0 and will be removed in 1.2.
            The Boston housing prices dataset has an ethical problem. You can refer to
            the documentation of this function for further details.
            The scikit-learn maintainers therefore strongly discourage the use of this
            dataset unless the purpose of the code is to study and educate about
            ethical issues in data science and machine learning.
            In this special case, you can fetch the dataset from the original
            source::
                import pandas as pd
                import numpy as np
                data_url = "http://lib.stat.cmu.edu/datasets/boston"
                raw_df = pd.read_csv(data_url, sep="\s+", skiprows=22, header=None)
                data = np.hstack([raw_df.values[::2, :], raw_df.values[1::2, :2]])
                target = raw_df.values[1::2, 2]
            Alternative datasets include the California housing dataset (i.e.
            :func:`~sklearn.datasets.fetch_california_housing`) and the Ames housing
            dataset. You can load the datasets as follows::
                from sklearn.datasets import fetch_california_housing
                housing = fetch_california_housing()
            for the California housing dataset and::
                from sklearn.datasets import fetch openml
                housing = fetch_openml(name="house_prices", as_frame=True)
            for the Ames housing dataset.
          warnings.warn(msg, category=FutureWarning)
B [40]: |print(boston_dataset.keys())
        # data: содержит информацию для различных домов
        # target: цены на дом
        # feature names: названия функций
        # DESCR: onucывает набор данных
        dict_keys(['data', 'target', 'feature_names', 'DESCR', 'filename', 'data_module'])
```

```
B [41]: print(boston_dataset.DESCR)
```

.. _boston_dataset:

Boston house prices dataset

Data Set Characteristics:

:Number of Instances: 506

:Number of Attributes: 13 numeric/categorical predictive. Median Value (attribute 14) is usually the target.

:Attribute Information (in order):

- CRIM per capita crime rate by town
- ZN proportion of residential land zoned for lots over 25,000 sq.ft.
- INDUS proportion of non-retail business acres per town
- CHAS Charles River dummy variable (= 1 if tract bounds river; 0 otherwise)
- NOX nitric oxides concentration (parts per 10 million)
- RM average number of rooms per dwelling
- AGE proportion of owner-occupied units built prior to 1940
- DIS weighted distances to five Boston employment centres
- RAD index of accessibility to radial highways
- TAX full-value property-tax rate per \$10,000
- PTRATIO pupil-teacher ratio by town
- B 1000(Bk 0.63)^2 where Bk is the proportion of black people by town
- LSTAT % lower status of the population
- MEDV Median value of owner-occupied homes in \$1000's

:Missing Attribute Values: None

:Creator: Harrison, D. and Rubinfeld, D.L.

This is a copy of UCI ML housing dataset.

https://archive.ics.uci.edu/ml/machine-learning-databases/housing/ (https://archive.ics.uci.edu/ml/machine-learning-databases/housing/)

This dataset was taken from the StatLib library which is maintained at Carnegie Mellon University.

The Boston house-price data of Harrison, D. and Rubinfeld, D.L. 'Hedonic prices and the demand for clean air', J. Environ. Economics & Management, vol.5, 81-102, 1978. Used in Belsley, Kuh & Welsch, 'Regression diagnostics ...', Wiley, 1980. N.B. Various transformations are used in the table on pages 244-261 of the latter.

The Boston house-price data has been used in many machine learning papers that address regression problems.

- .. topic:: References
- Belsley, Kuh & Welsch, 'Regression diagnostics: Identifying Influential Data and Sources of Collinearity', Wiley, 1980. 244-261.
- Quinlan, R. (1993). Combining Instance-Based and Model-Based Learning. In Proceedings on the Tenth International Conference of Machine Learning, 236-243, University of Massachusetts, Amherst. Morgan Kaufmann.
- B [42]: boston = pd.DataFrame(boston_dataset.data, columns=boston_dataset.feature_names)
 print(boston.shape)
 boston.head()

(506, 13)

Out[42]:

		CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	В	LSTAT
_	0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1.0	296.0	15.3	396.90	4.98
	1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2.0	242.0	17.8	396.90	9.14
	2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2.0	242.0	17.8	392.83	4.03
	3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3.0	222.0	18.7	394.63	2.94
	4	0 06905	0.0	2 18	0.0	0.458	7 147	54.2	6 0622	3.0	222 0	18 7	396 90	5 33

```
B [43]: boston.describe().T
```

Out[43]:

```
25%
                                                                     50%
                                                                                 75%
          count
                                    std
                                              min
                      mean
                                                                                           max
   CRIM
          506.0
                   3.613524
                               8.601545
                                           0.00632
                                                      0.082045
                                                                  0.25651
                                                                             3.677083
                                                                                        88.9762
                                                                  0.00000
     ΖN
          506.0
                  11.363636
                                           0.00000
                                                      0.000000
                                                                            12.500000
                              23.322453
                                                                                       100.0000
  INDUS
          506.0
                  11.136779
                               6.860353
                                           0.46000
                                                      5.190000
                                                                  9.69000
                                                                            18.100000
                                                                                        27.7400
                                           0.00000
   CHAS
          506.0
                   0.069170
                               0.253994
                                                      0.000000
                                                                  0.00000
                                                                             0.000000
                                                                                         1.0000
                   0.554695
    NOX
          506.0
                                           0.38500
                                                                  0.53800
                                                                                         0.8710
                               0.115878
                                                      0.449000
                                                                             0.624000
     RM
          506.0
                   6.284634
                               0.702617
                                           3.56100
                                                      5.885500
                                                                  6.20850
                                                                             6.623500
                                                                                         8.7800
          506.0
                  68.574901
                              28.148861
                                           2.90000
                                                     45.025000
                                                                 77.50000
                                                                            94.075000
    AGE
                                                                                       100.0000
                                                      2.100175
                                                                  3.20745
     DIS
          506.0
                   3.795043
                               2.105710
                                           1.12960
                                                                             5.188425
                                                                                        12.1265
                                           1.00000
          506.0
                   9.549407
                               8.707259
                                                      4.000000
                                                                  5.00000
                                                                            24.000000
    RAD
                                                                                        24.0000
                             168.537116
                                         187.00000
    TAX
          506.0
                408.237154
                                                    279.000000
                                                                330.00000
                                                                           666.000000
                                                                                       711.0000
                                          12.60000
PTRATIO
          506.0
                  18.455534
                               2.164946
                                                     17.400000
                                                                 19.05000
                                                                            20.200000
                                                                                        22.0000
          506.0
                 356.674032
                                           0.32000
                                                                           396.225000
                                                                                       396.9000
                              91.294864
                                                    375.377500
                                                                391.44000
  LSTAT 506.0
                  12.653063
                               7.141062
                                           1.73000
                                                      6.950000
                                                                 11.36000
                                                                            16.955000
                                                                                        37.9700
```

```
B [44]: # boston['MEDV'] = boston_dataset.target
target = boston_dataset["target"]
target[:10]
```

Out[44]: array([24., 21.6, 34.7, 33.4, 36.2, 28.7, 22.9, 27.1, 16.5, 18.9])

Предварительная обработка данных

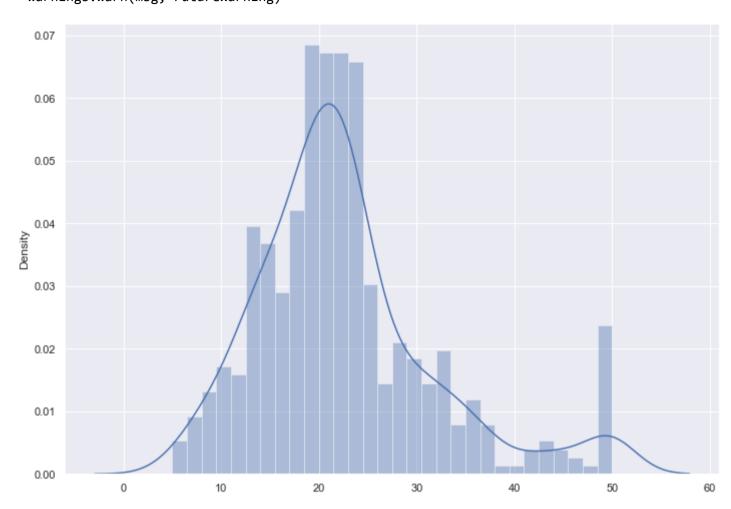
```
B [45]: boston.isnull().sum()
Out[45]: CRIM
          ZN
                     0
          INDUS
                     0
          CHAS
                     0
          NOX
                     0
          RM
                     0
          AGE
                     0
                     0
          DIS
          RAD
          TAX
                     0
          PTRATIO
          LSTAT
          dtype: int64
```

Исследовательский анализ данных

```
B [46]: import seaborn as sns
```

```
B [47]: sns.set(rc={'figure.figsize':(11.7,8.27)})
sns.distplot(target, bins=30)
plt.show()
```

C:\ProgramData\Anaconda3\lib\site-packages\seaborn\distributions.py:2551: FutureWarning: `distplot` is a deprecated fun
ction and will be removed in a future version. Please adapt your code to use either `displot` (a figure-level function
with similar flexibility) or `histplot` (an axes-level function for histograms).
 warnings.warn(msg, FutureWarning)



```
B [48]: correlation_matrix = boston.corr().round(2)
# annot = True to print the values inside the square
sns.heatmap(data=correlation_matrix, annot=True)
```

Out[48]: <AxesSubplot:>



Коэффициент корреляции варьируется от -1 до 1. Если значение близко к 1, это означает, что между двумя переменными существует сильная положительная корреляция. Когда оно близко к -1, переменные имеют сильную отрицательную корреляцию.

```
B [50]: plt.figure(figsize=(15, 20))
          # features = ['LSTAT', 'RM']
          # target = boston['MEDV']
          features = boston.keys()
          for i, col in enumerate(features):
              plt.subplot(5, 3, i+1)
              x = boston[col]
              y = target
              plt.scatter(x, y, marker='o')
              # plt.title(col)
              plt.xlabel(col)
              plt.ylabel('MEDV')
             50
             40
                                                            40
           MEDV
30
                                                         MEDV
30
                                                                                                        MEDV
30
             20
                                                                                                          20
                                                            20
             10
                                                            10
                                                                                                          10
                                                                       20
                                                                                                   100
                                                                                                                                 15
                                 40
                                                                0
                                                                              40
                                                                                                              0
                                                                                                                           10
                                 CRIM
                                                                                                                              INDUS
             50
                                                            50
                                                                                                          50
             40
                                                                                                          40
                                                            40
           MEDV
30
                                                                                                        MEDV
                                                         MEDV
                                                           30
             20
                                                            20
                                                                                                          20
             10
                                                            10
                 0.0
                        0.2
                                      0.6
                                                                                              0.8
                                                                                                                                             8
                                                                                NOX
                                                                                                                                RM
                                 CHAS
             50
                                                                                                          50
             40
           MEDV
30
                                                                                                        MEDV
             20
                                                            20
                                                                                                          20
             10
                                                                                                          10
                                      60
                                                                                                   12
                                                                                                             0
                                                                                                                            10
                 0
                                                    100
                                                                                            10
                                                                                                                                    15
                                                                                                                               RAD
             50
                                                            50
                                                                                                          50
                                                                                                          40
           MEDV
30
                                                                                                        MEDV
30
                                                         MEDV
             10
                                                            10
                  200
                               400
                                      500
                                             600
                                                    700
                                                                     14
                                                                                            20
                                                                                                   22
                                                                                                                                200
                                                                                                                                         300
                                                                                                                                                 400
                                  TAX
                                                                              PTRATIO
                                                                                                                                В
           MEDV
             20
             10
                0
                          10
                                   20
                                 LSTAT
```

Замечания:

- Цены растут по мере линейного увеличения стоимости RM. Существует несколько выбросов, и данные, похоже, ограничены 50.
- Цены имеют тенденцию к снижению с ростом LSTAT (не линейно).

```
B [19]: # # репрезентация данных в виде графиков
# g = sns.pairplot(boston)
# plt.show() # расскоментируйте, чтобы посмотреть
```

Практическое задание

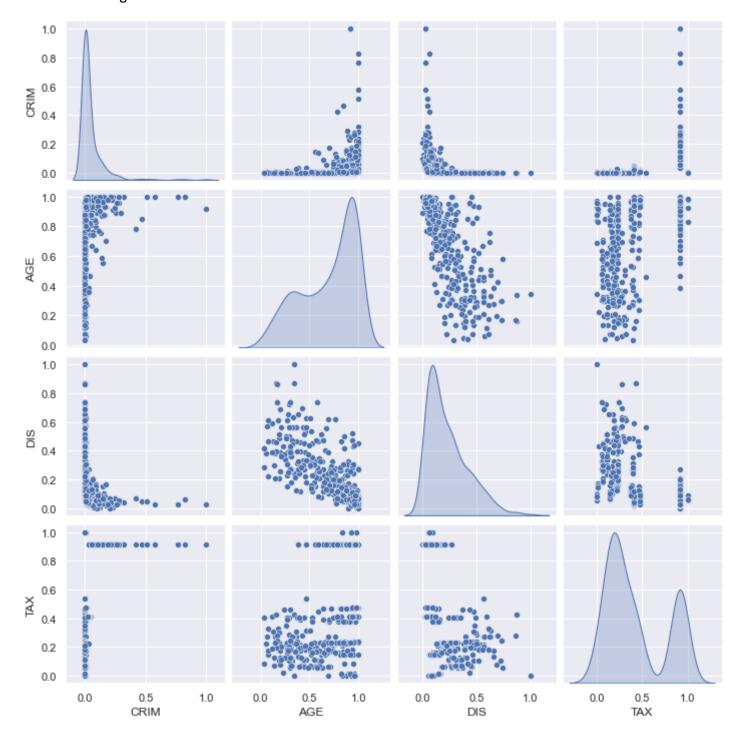
- 1. Постройте нейронную сеть (берём простую линейную сеть, которую разбирали на уроке: меняем число слоёв, число нейронов, типы активации, тип оптимизатора) на датасете from sklern.datasets import load_boston.
- 2. Измените функцию потерь и метрику для этой задачи. Постройте 10-15 вариантов и сведите результаты их работы в таблицу. Опишите, какого результата вы добились от нейросети? Что помогло вам улучшите её точность?

Разделение данных на обучающие и тестовые наборы

```
B [54]: | from sklearn.preprocessing import MinMaxScaler
        scaler_data = MinMaxScaler()
        train_data = scaler_data.fit_transform(boston)
B [56]: from sklearn.model_selection import train_test_split
        from sklearn.metrics import r2_score
        train_data = pd.DataFrame(train_data, columns=boston_dataset["feature_names"])
        # X_train, X_test, y_train, y_test = train_test_split(boston, target, test_size = 0.2, random_state=5)
        X_train, X_test, y_train, y_test = train_test_split(train_data, target, test_size=0.25)
        print(X_train.shape)
        print(X_test.shape)
        print(y_train.shape)
        print(y_test.shape)
        (379, 13)
        (127, 13)
        (379,)
        (127,)
```

```
B [59]: sns.pairplot(X_train[["CRIM","AGE","DIS","TAX"]], diag_kind="kde")
```

Out[59]: <seaborn.axisgrid.PairGrid at 0xf9a2015490>



```
В []: # определим число нейронов скрытого слоя (ширина скрытого слоя)

пешrons = [50, 100, 200]

# определим скорость обучения (Learning rate)

# п = [0.005, 0.05, 0.5, 1.0]

# определим количество эпох

# еросh_пить = [100, 1000, 5000]

# определим оптимизаторы

орtimizers = ['SGD','RMSProp','adam','NAdam']

# определим метрики

metrics = ['MSE', 'MAE']
```

```
B [27]: # input6 = keras.layers.Input( shape=(28, 28) )
# x6 = keras.layers.Platten()(input6)
# x6 = keras.layers.Dense(256, activation='relu')(x6)
# x6 = keras.layers.Dense(1, activation='sigmoid')(x6)

# model6 = Model(inputs=input6,outputs=x6)
# model6.compile(optimizer=tf.keras.optimizers.Adagrad(lr=0.1, epsilon=1e-08, decay=0.0),
# loss=tf.keras.losses.BinaryCrossentropy(),
# metrics=['accuracy'])

# model6.fit(train_images,y_train_labels[:,6], epochs = 10, validation_split = 0.2)
```

```
B [28]: from sklearn.metrics import mean_squared_error
        colNames = ["neurons", "epochs", "optimizer", "metric",
                    "loss (test)", "metric_val (test)", "rmse (test)", "r2 (test)" ]
        model_3_layers = pd.DataFrame(columns=colNames)
        k = 1000 \# количество эпох
        for i in neurons: # ширина скрытого слоя
              for j, i_optim in enumerate([keras.optimizers.RMSprop(),keras.optimizers.SGD(),keras.optimizers.Adam()]):
            for i_optim in optimizers: # onmuмизаторы
                for k_metric in metrics: # метрики
                   x_input = keras.layers.Input( shape=(13))
                   x = keras.layers.Dense(i, activation='relu')(x_input)
                   x_{output} = keras.layers.Dense(1)(x)
                   model = keras.models.Model(inputs=x_input, outputs=x_output)
                    model.compile(
                       optimizer=i_optim,
                       loss='mae',
                       metrics=[k_metric])
                   model.fit(
                       X_train,
                       y_train,
                       epochs=k,
                       batch_size=100,
                       # validation_split=0.2, # использовать 20 % данных для валидации
                       verbose=0
                   )
                   # model evaluation for training set
                   loss_metric_train = model.evaluate(X_train, y_train)
                   y_train_predict = model.predict(X_train)
                    rmse_train = (np.sqrt(mean_squared_error(y_train, y_train_predict)))
                   r2_train = r2_score(y_train, y_train_predict)
                    # model evaluation for testing set
                   loss_metric_test = model.evaluate(X_test, y_test)
                   y_test_predict = model.predict(X_test)
                    rmse_test = (np.sqrt(mean_squared_error(y_test, y_test_predict)))
                   r2_test = r2_score(y_test, y_test_predict)
                     print(k_metric)
                    model_3_layers = model_3_layers.append(pd.DataFrame({
                        'neurons': [i],
                        'скорость обучения': [n],
                        'epochs': [k],
                        'optimizer': i_optim,
                        'metric': k_metric,
                        'loss (train)': [loss_metric_train[0]],
                        'metric_val (train)': [loss_metric_train[1]],
                        'rmse (train)': [rmse_train],
                        'r2 (train)': [r2_train],
                        'loss (test)': [loss_metric_test[0]],
                        'metric_val (test)': [loss_metric_test[1]],
                        'rmse (test)': [rmse_test],
                        'r2 (test)': [r2_test]}),
                       ignore_index=True)
        12/12 [============== ] - 0s 1ms/step - loss: 2.6603 - MSE: 18.6085
```

```
12/12 [================== ] - 0s 2ms/step - loss: 2.7214 - MAE: 2.7214
12/12 [============== ] - 0s 2ms/step - loss: 2.9428 - MAE: 2.9428
12/12 [============== ] - 0s 2ms/step - loss: 2.6479 - MAE: 2.6479
```

04.01.2022. 21:26

Out[29]:

```
4/4 [============ ] - 0s 3ms/step - loss: 2.6255 - MSE: 20.7431
4/4 [=============== ] - 0s 3ms/step - loss: 2.8415 - MSE: 22.7509
12/12 [============= ] - 0s 3ms/step - loss: 2.2836 - MAE: 2.2836
12/12 [============= ] - 0s 3ms/step - loss: 2.1548 - MAE: 2.1548
4/4 [=============== ] - 0s 4ms/step - loss: 2.7222 - MSE: 21.7673
```

B [29]: # pd.options.display.max_columns = None
pd.options.display.max_rows = None
model_3_layers.sort_values(by='r2 (test)', ascending=False)

	neurons	epochs	optimizer	metric	loss (train)	metric_val (train)	rmse (train)	r2 (train)	loss (test)	metric_val (test)	rmse (test)	r2 (test)
20	200	1000	adam	MSE	2.033568	13.088802	3.617845	0.854712	2.532759	18.202017	4.266382	0.726369
18	200	1000	RMSProp	MSE	2.175313	14.330061	3.785507	0.840934	2.613506	19.041100	4.363611	0.713755
21	200	1000	adam	MAE	2.154835	2.154835	3.787960	0.840728	2.609661	2.609661	4.395317	0.709580
19	200	1000	RMSProp	MAE	2.283551	2.283551	3.950742	0.826745	2.645793	2.645793	4.484584	0.697664
10	100	1000	RMSProp	MSE	2.426916	16.639341	4.079135	0.815301	2.635586	20.248686	4.499854	0.695601
11	100	1000	RMSProp	MAE	2.420751	2.420751	4.046276	0.818264	2.683014	2.683014	4.507568	0.694557
2	50	1000	RMSProp	MSE	2.520309	17.334049	4.163418	0.807589	2.723081	20.585991	4.537179	0.690531
12	100	1000	adam	MSE	2.258771	15.623443	3.952650	0.826577	2.625455	20.743137	4.554463	0.688168
13	100	1000	adam	MAE	2.364052	2.364052	4.111797	0.812331	2.700979	2.700979	4.644477	0.675720
22	200	1000	NAdam	MSE	2.352403	16.765678	4.094592	0.813898	2.722205	21.767317	4.665545	0.672772
23	200	1000	NAdam	MAE	2.283510	2.283510	4.020187	0.820600	2.694912	2.694912	4.672455	0.671802
15	100	1000	NAdam	MAE	2.667193	2.667193	4.368858	0.788132	2.785326	2.785326	4.672460	0.671801
9	100	1000	SGD	MAE	2.647913	2.647913	4.330896	0.791798	2.849529	2.849529	4.729398	0.663753
0	50	1000	SGD	MSE	2.660324	18.608490	4.313756	0.793443	2.844080	22.524300	4.745977	0.661392
3	50	1000	RMSProp	MAE	2.591540	2.591540	4.269142	0.797693	2.765797	2.765797	4.762915	0.658971
17	200	1000	SGD	MAE	2.673540	2.673540	4.332473	0.791646	2.868333	2.868333	4.766646	0.658436
16	200	1000	SGD	MSE	2.669021	18.989975	4.357749	0.789208	2.841514	22.750919	4.769792	0.657985
4	50	1000	adam	MSE	2.768833	19.537346	4.420107	0.783132	2.940224	22.857212	4.780922	0.656387
8	100	1000	SGD	MSE	2.699124	19.123608	4.373054	0.787725	2.858680	22.915777	4.787043	0.655507
7	50	1000	NAdam	MAE	2.856231	2.856231	4.607445	0.764360	2.931466	2.931466	4.836031	0.648420
1	50	1000	SGD	MAE	2.721354	2.721354	4.414626	0.783670	2.940151	2.940151	4.846568	0.646886
6	50	1000	NAdam	MSE	2.798899	20.060415	4.478885	0.777326	2.951890	23.903143	4.889084	0.640664
5	50	1000	adam	MAE	2.942799	2.942799	4.697543	0.755054	2.890187	2.890187	4.899943	0.639066
14	100	1000	NAdam	MSE	2.793050	20.881323	4.569609	0.768214	2.897529	24.014818	4.900491	0.638985

Лучшее значения на test-е при количестве нейронов=200, количество слоёв=3, optimizer='RMSProp', тип активации='relu', metric='MSE' и составил r2 = 0.726369.

train: r2 = 0.854712test: r2 = 0.726369

Для train:

- loss = 2.033568
- metrics values=13.088802
- rmse = 3.617845
- r2 = 0.854712

Для test:

• loss=2.532759

- metrics values=18.202017
- rmse = 4.266382
- r2 = 0.726369

Увеличим количество слоёв и проверим как изменился результат.

```
B [31]: model_n_layers = pd.DataFrame(columns=colNames)
        k = 1000 + количество эпох
        for i in neurons: # ширина скрытого слоя
            for i_optim in optimizers: # onmuмизаторы
                for k_metric in metrics: # метрики
                    x_input = keras.layers.Input( shape=(13))
                    x = keras.layers.Dense(i, activation='relu')(x_input)
                    x_1 = keras.layers.Dense(i, activation='relu')(x)
                    x_2 = keras.layers.Dense(i, activation='relu')(x_1)
                    x_{output} = keras.layers.Dense(1)(x_2)
                    model = keras.models.Model(inputs=x_input, outputs=x_output)
                    model.compile(
                        optimizer=i_optim,
                        loss='mae',
                        metrics=[k_metric])
                    model.fit(
                        X_train,
                        y_train,
                        epochs=k,
                        batch_size=100,
                        # validation_split=0.2, # использовать 20 % данных для валидации
                        verbose=0
                    # model evaluation for training set
                    loss_metric_train = model.evaluate(X_train, y_train)
                    y_train_predict = model.predict(X_train)
                    rmse_train = (np.sqrt(mean_squared_error(y_train, y_train_predict)))
                    r2_train = r2_score(y_train, y_train_predict)
                    # model evaluation for testing set
                    loss_metric_test = model.evaluate(X_test, y_test)
                    y_test_predict = model.predict(X_test)
                    rmse_test = (np.sqrt(mean_squared_error(y_test, y_test_predict)))
                    r2_test = r2_score(y_test, y_test_predict)
                      print(k_metric)
                    model_n_layers = model_3_layers.append(pd.DataFrame({
                        'neurons': [i],
                        'скорость обучения': [n],
                        'epochs': [k],
                         'optimizer': i_optim,
                        'metric': k_metric,
                         'loss (train)': [loss_metric_train[0]],
                         'metric_val (train)': [loss_metric_train[1]],
                        'rmse (train)': [rmse_train],
                        'r2 (train)': [r2_train],
                        'loss (test)': [loss_metric_test[0]],
                        'metric_val (test)': [loss_metric_test[1]],
                         'rmse (test)': [rmse_test],
                         'r2 (test)': [r2_test]}),
                        ignore_index=True)
        12/12 [================== ] - 0s 2ms/step - loss: 1.9990 - MSE: 11.0744
```

```
4/4 [=============== ] - 0s 3ms/step - loss: 2.4897 - MSE: 16.3536
4/4 [=============== ] - 0s 3ms/step - loss: 2.3649 - MSE: 14.8665
12/12 [================= ] - Øs 2ms/step - loss: 1.6359 - MAE: 1.6359
12/12 [=============== ] - 0s 3ms/step - loss: 1.5695 - MAE: 1.5695
4/4 [============== ] - 0s 3ms/step - loss: 2.4338 - MSE: 13.9453
12/12 [============= ] - 0s 2ms/step - loss: 0.9760 - MSE: 2.8693
```

```
12/12 [=================== ] - 0s 2ms/step - loss: 0.8756 - MAE: 0.8756
```

B [32]:

model_n_layers.sort_values(by='r2 (test)', ascending=False)

Out[32]:

	neurons	epochs	optimizer	metric	loss (train)	metric_val (train)	rmse (train)	r2 (train)	loss (test)	metric_val (test)	rmse (test)	r2 (test)
24	200	1000	NAdam	MAE	0.875556	0.875556	1.325170	0.980507	2.060283	2.060283	3.186189	0.847388
20	200	1000	adam	MSE	2.033568	13.088802	3.617845	0.854712	2.532759	18.202017	4.266382	0.726369
18	200	1000	RMSProp	MSE	2.175313	14.330061	3.785507	0.840934	2.613506	19.041100	4.363611	0.713755
21	200	1000	adam	MAE	2.154835	2.154835	3.787960	0.840728	2.609661	2.609661	4.395317	0.709580
19	200	1000	RMSProp	MAE	2.283551	2.283551	3.950742	0.826745	2.645793	2.645793	4.484584	0.697664
10	100	1000	RMSProp	MSE	2.426916	16.639341	4.079135	0.815301	2.635586	20.248686	4.499854	0.695601
11	100	1000	RMSProp	MAE	2.420751	2.420751	4.046276	0.818264	2.683014	2.683014	4.507568	0.694557
2	50	1000	RMSProp	MSE	2.520309	17.334049	4.163418	0.807589	2.723081	20.585991	4.537179	0.690531
12	100	1000	adam	MSE	2.258771	15.623443	3.952650	0.826577	2.625455	20.743137	4.554463	0.688168
13	100	1000	adam	MAE	2.364052	2.364052	4.111797	0.812331	2.700979	2.700979	4.644477	0.675720
22	200	1000	NAdam	MSE	2.352403	16.765678	4.094592	0.813898	2.722205	21.767317	4.665545	0.672772
23	200	1000	NAdam	MAE	2.283510	2.283510	4.020187	0.820600	2.694912	2.694912	4.672455	0.671802
15	100	1000	NAdam	MAE	2.667193	2.667193	4.368858	0.788132	2.785326	2.785326	4.672460	0.671801
9	100	1000	SGD	MAE	2.647913	2.647913	4.330896	0.791798	2.849529	2.849529	4.729398	0.663753
0	50	1000	SGD	MSE	2.660324	18.608490	4.313756	0.793443	2.844080	22.524300	4.745977	0.661392
3	50	1000	RMSProp	MAE	2.591540	2.591540	4.269142	0.797693	2.765797	2.765797	4.762915	0.658971
17	200	1000	SGD	MAE	2.673540	2.673540	4.332473	0.791646	2.868333	2.868333	4.766646	0.658436
16	200	1000	SGD	MSE	2.669021	18.989975	4.357749	0.789208	2.841514	22.750919	4.769792	0.657985
4	50	1000	adam	MSE	2.768833	19.537346	4.420107	0.783132	2.940224	22.857212	4.780922	0.656387
8	100	1000	SGD	MSE	2.699124	19.123608	4.373054	0.787725	2.858680	22.915777	4.787043	0.655507
7	50	1000	NAdam	MAE	2.856231	2.856231	4.607445	0.764360	2.931466	2.931466	4.836031	0.648420
1	50	1000	SGD	MAE	2.721354	2.721354	4.414626	0.783670	2.940151	2.940151	4.846568	0.646886
6	50	1000	NAdam	MSE	2.798899	20.060415	4.478885	0.777326	2.951890	23.903143	4.889084	0.640664
5	50	1000	adam	MAE	2.942799	2.942799	4.697543	0.755054	2.890187	2.890187	4.899943	0.639066
14	100	1000	NAdam	MSE	2.793050	20.881323	4.569609	0.768214	2.897529	24.014818	4.900491	0.638985

Лучшее значения на test-е при количестве нейронов=200, количество слоёв=5, optimizer='RMSProp', тип активации='relu', metric='MSE' и составил r2 = 0.847388.

- train: r2 = 0.980507
- **test**: **r2** = 0.847388

Для **train**:

- loss = 0.875556
- metrics values=0.875556
- rmse = 1.325170
- **r2** = 0.980507

Для test:

- loss=2.060283
- metrics values=2.060283
- rmse = 3.186189
- **r2** = 0.847388

Результат улучшился:

- test: r2 = 0.847388 для 5 слоёв, против r2 = 0.726369 для 3 слоёв.
- train: r2 = 0.980507 для 5 слоёв, против r2 = 0.854712 для 3 слоёв.

Улучшить точность нейросети помогли следующие факторы:

- выбор подходящего оптимизатора,
- подбор оптимального количества нейронов,
- увеличение количества слоёв,
- r2 колебался от 0,64 до 0,86 (при неизменных параметрах).

Практическое задание

3. Поработайте с документацией TensorFlow 2. Найти 2-3 полезные команды TensorFlow, не разобранные на уроке (полезные для Вас).

https://www.tensorflow.org/api_docs/python/tf (https://www.tensorflow.org/api_docs/python/tf)

- tf.Graph(): A TensorFlow computation, represented as a dataflow graph.
- tf.size(): Returns the size of a tensor.
- tf.image module contains various functions for image processing and decoding-encoding Ops.
 - resize(): Resize images to size using the specified method.
 - resize with pad(): Crops and/or pads an image to a target width and height.
 - convert_image_dtype(): Convert image to dtype, scaling its values if needed.
- tf.summary Operations for writing summary data, for use in analysis and visualization.
 - audio(): Write an audio summary.
 - text(): Write a text summary.
 - image(): Write an image summary.

B []:	
B []:	
B []:	

- 1. Как меняется нейронная сеть под действием задачи?
- 2. Выход не м.б. ограниченным => либо 'relu' либо линейная.
- 3. loss должен учитывать характеристики задачи.
- 4. Метрика учитывает вид выхода, тип задачи (при выборе потерь и метрики):
 - квадратичная ошибка, абсолютная ошибка, коэффициент детерминации

OpenCV (англ. Open Source Computer Vision Library, библиотека компьютерного зрения с открытым исходным кодом) — библиотека алгоритмов компьютерного зрения, обработки изображений и численных алгоритмов общего назначения с открытым кодом. Реализована на C/C++, также разрабатывается для Python, Java, Ruby, Matlab, Lua и других языков[2]. Может свободно использоваться в академических и коммерческих целях — распространяется в условиях лицензии BSD.

TensorFlow — Введение

https://coderlessons.com/tutorials/mashinnoe-obuchenie/vyuchit-tensorflow/tensorflow-kratkoe-rukovodstvo (https://coderlessons.com/tutorials/mashinnoe-obuchenie/vyuchit-tensorflow/tensorflow-kratkoe-rukovodstvo)

Искусственный интеллект включает в себя процесс моделирования человеческого интеллекта с помощью машин и специальных компьютерных систем. Примеры искусственного интеллекта включают обучение, рассуждение и самокоррекцию. Приложения искусственного интеллекта включают распознавание речи, экспертные системы, распознавание изображений и машинное зрение.

Машинное обучение — это отрасль искусственного интеллекта, которая занимается системами и алгоритмами, которые могут изучать любые новые данные и шаблоны данных.

В []:	